

M4 Competition и архитектура N-BEATS

Deep Learning для Forecasting

План презентации

- 1 M4 Competition
- 2 Идея N-BEATS
- 3 Архитектура N-BEATS
- 4 Generic vs Interpretable
- 5 Параметры и Ensemble
- 6 Результаты
- 7 Заключение

Что такое M4 Competition

- Крупнейшее международное соревнование по forecasting
- Более 100 000 временных рядов
- Цель:
 - сравнение методов прогнозирования;
 - поиск универсальных моделей;
 - оценка способности моделей к обобщению.
- Разные частоты:

Yearly, Quarterly, Monthly, Weekly, Daily, Hourly

- M4 стал основным benchmark для forecasting research

Главный вывод M4: классические statistical ensembles долгое время превосходили deep learning.

Domain	Series	Horizon
Finance	24 534	6–48
Macro	19 402	6–48
Micro	25 121	6–48
Industry	18 798	6–48
Demographic	8 708	6–18
Other	3 437	6–48

- разнородные наборы данных;
- разные масштабы и сезонности;
- высокая вариативность длин рядов;
- сложная задача generalized forecasting.

Классические методы

- ETS
- ARIMA
- Theta method
- statistical ensembles

Почему statistical methods доминировали

- сильные априорные предположения модели;
- устойчивость на малых данных;
- хорошая интерпретируемость.

Почему DL долго проигрывал

- мало данных на ряд;
- overfitting;
- сложность сезонностей;
- зависимость от повторений.

N-BEATS

- первая pure DL architecture;
- SOTA на M4;
- без RNN/LSTM;
- без handcrafted TS blocks.

sMAPE

$$\text{sMAPE} = \frac{200}{H} \sum_{t=1}^H \frac{|y_t - \hat{y}_t|}{|y_t| + |\hat{y}_t|}$$

- не зависит от масштаба;
- симметрична относительно ошибок.

MASE

$$\text{MASE} = \frac{\frac{1}{H} \sum |y_t - \hat{y}_t|}{\text{Naive forecast error}}$$

- сравнение с naive baseline;
- учитывает сезонность.

OWA

$$\text{OWA} = \frac{1}{2} \left(\frac{\text{sMAPE}}{\text{sMAPE}_{\text{Naive2}}} + \frac{\text{MASE}}{\text{MASE}_{\text{Naive2}}} \right)$$

- основная метрика M4;

Принципы проектирования N-BEATS

Идея авторов

Проверить, может ли простая deep learning архитектура достигать SOTA-качества в forecasting без специализированных компонентов для временных рядов.

Ключевые принципы

- простая и универсальная архитектура;
- глубокая и достаточно выразительная модель;
- отсутствие feature engineering;
- отсутствие специальных TS-модулей;
- минимальные априорные предположения.

Главная цель

- исследовать потенциал pure deep learning;
- проверить scalability FC-сетей;
- построить архитектуру, пригодную для интерпретации.

Главная идея N-BEATS

Ключевая гипотеза

Forecast можно строить итеративно: каждый block объясняет часть сигнала, а residual передаётся следующим блокам.


Интуиция

- каждый block выделяет часть структуры ряда;
- residual передаётся дальше;
- прогноз постепенно уточняется;
- архитектура напоминает boosting.


Главная идея

Модель постепенно декомпозирует временной ряд: ранние блоки объясняют грубые компоненты, а поздние корректируют residual.

Double Residual Stacking в N-BEATS



Полная архитектура N-BEATS



Две конфигурации N-BEATS

Главная идея

Авторы предложили две версии архитектуры:

- **Generic N-BEATS** — полностью data-driven модель;
- **Interpretable N-BEATS** — модель с явной декомпозицией trend + seasonality.

Generic архитектура

- нет специальных предположений о структуре TS;
- базис обучается сетью;
- basis functions формируются автоматически;
- максимальная гибкость модели;
- высокая forecasting accuracy.

Interpretable архитектура

- вводятся структурные ограничения;
- отдельные stacks для:
 - trend;
 - seasonality.
- фиксированные basis functions;
- интерпретируемая декомпозиция.

Generic N-BEATS

- полностью data-driven;
- обучаемые basis functions;
- нет фиксированных seasonal/trend предположений;
- максимальная flexibility.

Forecast блока

$$\hat{y}^{(i)} \in \mathbb{R}^{T_{out}}$$


$$\hat{y}^{(i)} = g_f = W_f h + b_f$$

Backcast блока

$$\hat{x}^{(i)} \in \mathbb{R}^{T_{in}}$$

GENERIC N-BEATS BLOCK

(универсальный блок без явного базиса)



Trend stack

$$\hat{y}^{trend} = \sum_{i=0}^p \theta_i t^i$$

- polynomial basis;
- smooth long-term behavior.

Seasonality stack

$$\hat{y}^{season} = \sum_i a_i \cos(2\pi it) + b_i \sin(2\pi it)$$

- harmonic basis;
- periodic structure.

Интерпретация


Forecast раскладывается на:

$$\hat{y} = \hat{y}^{trend} + \hat{y}^{season}$$

- похоже на STL decomposition;
- trend и seasonality доступны отдельно;
- более понятная модель.

INTERPRETABLE N-BEATS BLOCK

(Trend Block / Seasonality Block)



Trend Block

Использует polynomial basis
(например, $1, t, t^2, t^3, \dots$)



Seasonality Block

Использует harmonic basis
(например, $\sin(2\pi t/P), \cos(2\pi t/P), \dots$)

Generic vs Interpretable

	Generic	Interpretable
Basis	Learned	Fixed
Interpretability	Low	High
Flexibility	High	Medium
Trend/Seasonality	Implicit	Explicit
Forecast quality	Very high	High

Главный trade-off

Accuracy $\leftrightarrow$ Interpretability

На практике обе версии показывают близкое качество на M4.

Parameter	Typical value
Stacks	2–30
Blocks per stack	3–5
FC layers	4
Hidden dimension	256–2048
Backcast length	$2H \dots 7H$
Forecast horizon	depends on dataset
Optimizer	Adam
Learning rate	10^{-3}

- глубокая fully-connected architecture;
- очень большой receptive field;
- масштабируемость на разные horizons.

Ансамбль моделей в N-BEATS

Почему ансамбль важен

Все топ-решения M4 использовали ensemble-подходы. Для N-BEATS ансамбль оказался эффективнее классической регуляризации.

Observation из статьи

- dropout и L2 улучшали отдельные модели;
- но ухудшали качество ensemble;
- разнообразие оказалось главным фактором качества.

Источники разнообразия N-Beats

- разные loss functions:
sMAPE, MASE, MAPE
- разные random initialization;
- независимое обучение моделей.

Разные input windows

Для каждого forecasting horizon H использовались окна:

$$\{2H, 3H, 4H, 5H, 6H, 7H\}$$

Интуиция

- короткие окна:
 - локальная динамика;
 - быстрые изменения.
- длинные окна:
 - долгосрочные тренды;
 - сезонность.

Aggregation

$$\hat{y}_{ensemble} = \text{median}(\hat{y}_1, \dots, \hat{y}_M)$$

Method	sMAPE	OWA
Statistical benchmark	11.986	0.861
Hybrid methods	11.720	0.838
M4 Winner (Smyl)	11.374	0.821
N-BEATS-G	11.168	0.797
N-BEATS-I+G	11.135	0.795

- pure deep learning превзошла statistical ensembles;
- без RNN/LSTM-специфичных компонент;
- сильный результат на heterogeneous datasets.

Что показал N-BEATS

- deep learning может работать в forecasting;
- recurrence не обязательна;
- FC architectures оказались неожиданно эффективными;
- residual decomposition улучшает качество;
- interpretable DL возможен.

Сильные стороны

- высокая accuracy;
- простая архитектура;
- масштабируемость;
- interpretability option.

Идея экспериментальных улучшений

Контекст

Оригинальный N-BEATS показал, что простая полносвязная архитектура может достигать SOTA. Берём этот baseline и проверяем две независимых гипотезы.

Два А/В-эксперимента

① EXP1 — RevIN

замена max-divide нормализации на reversible instance normalization;

② EXP3 — Multi-head

дешёвый внутримодельный ансамбль: один backbone, K голов с разными лоссами.



Протокол сравнения

В каждом эксперименте: paired runs baseline vs treatment, 3 сета, фиксированный seed split-by-series, sMAPE-метрика.

Методология: test на best-val, не на финальной

Финальная модель (50k шагов) переобучена. Берём чекпоинт с минимальным val_smape и считаем test sMAPE на этом шаге.

Зачем мерить test на best-val: финальная модель переобучена (★ = best-val step)



EXP1: проблема нестационарности

Слабая стационарность

$$\mathbb{E}[y_t] = \mu, \quad \text{Var}[y_t] = \sigma^2, \quad \text{Cov}(y_t, y_{t+\tau}) = \gamma(\tau)$$

Реальные ряды M4 нестационарны:

$$y_t = \mu_t + \sigma_t \cdot \varepsilon_t, \quad \varepsilon_t \sim \mathcal{N}(0, 1)$$

где μ_t, σ_t медленно меняются во времени.

Что делал baseline N-BEATS

$$x \leftarrow \frac{x}{\max |x|}$$

- сохраняет масштаб, теряет μ_t ;
- не адаптируется к dirft в данных.

EXP1: формула RevIN

Normalize (внутри forward):

$$\hat{\mu} = \frac{1}{L} \sum_i x_i, \quad \hat{\sigma}^2 = \frac{1}{L} \sum_i (x_i - \hat{\mu})^2 + \epsilon, \quad \tilde{x}_i = \gamma \cdot \frac{x_i - \hat{\mu}}{\hat{\sigma}} + \beta$$

γ, β — обучаемые параметры ($\gamma=1, \beta=0$ при инициализации).

Denormalize (после backbone'a):

$$\hat{y}_h = \frac{\tilde{y}_h - \beta}{\gamma} \cdot \hat{\sigma} + \hat{\mu}$$

Интуиция

Backbone видит стандартизованный сигнал, прогноз возвращается в исходный масштаб.
Локальные μ_t, σ_t снимаются рег-окно.

Обёртка вокруг существующей сети

- ни одной строчки внутри NBeatsNet не меняется;
- RevIN живёт снаружи как drop-in wrapper.



$$\text{NBeatsWithRevIN} : x \xrightarrow{\text{normalize}} \tilde{x} \xrightarrow{\text{NBeatsNet}} \tilde{y} \xrightarrow{\text{denormalize}} \hat{y}$$

А/В-сравнение

- baseline: max-divide норма + sMAPE-loss;
- +RevIN: RevIN-обёртка + sMAPE-loss.

EXP1: кривые обучения


EXP1: baseline vs +RevIN — test sMAPE (★ = mean best-val step)



Hourly: RevIN-кривая стабильно ниже baseline'а. Monthly: разделения почти нет. ★ = best-val шаг (mean по 3 сидам).

EXP1: парные различия по сидам

EXP1: парные различия по сидам



- Hourly: все 3 сида ниже нуля, $\Delta = -0.19$ п.п., $p = 0.008$ — эффект значимый и воспроизводимый;
- Monthly: смешано, null effect.

EXP3: multi-head как дешёвый ансамбль

Идея

Классический ансамбль K независимых моделей дорогой ($K \times$ параметров). Берём общий backbone f_θ + K независимых линейных голов g_k :

$$\hat{y}^{(k)} = g_k(f_\theta(x)), \quad k = 1, \dots, K$$

Каждую голову обучаем под свой лосс, на инференсе усредняем:

$$\mathcal{L} = \mathcal{L}_{\text{MAE}}(\hat{y}^{(1)}, y) + \mathcal{L}_{\text{sMAPE}}(\hat{y}^{(2)}, y) + \mathcal{L}_{\text{MSE}}(\hat{y}^{(3)}, y), \quad \hat{y} = \frac{1}{K} \sum_{k=1}^K \hat{y}^{(k)}$$

Гипотеза

Разные лоссы дают де-коррелированные ошибки голов $\Rightarrow$ усреднение снижает дисперсию.

Структура



- один NBeatsNet как shared backbone;
- $K=3$ независимых nn.Linear(H , H) поверх;
- доп. параметров $K \cdot H^2$ — тривиально, один forward.

A/B-сравнение

- baseline: single-head, sMAPE-loss;
- +multihead: $K=3$ голов, $\mathcal{L}_{\text{MAE}} + \mathcal{L}_{\text{sMAPE}} + \mathcal{L}_{\text{MSE}}$.

EXP3: кривые обучения



EXP3: baseline vs multihead — test sMAPE (★ = mean best-val step)



Hourly: multihead-кривая выше baseline'а на ~ 0.1 п.п. Monthly: чуть выше, в пределах шума. ★ = best-val шаг.


EXP3: per-head анализ

Multihead: ансамбль не побеждает лучшую одиночную голову (MSE-голова стабильно хуже остальных)



- MSE-голова стабильно хуже на обеих частотах;
- sMAPE-голова $\leq$ усреднению — одна голова не хуже ансамбля;
- гипотеза «де-коррелированные головы помогают» опровергнута.

EXP3: парные различия по сидам



- Hourly: точки разбросаны ($s_0 = -0.13$, $s_1 = -0.27$, $s_2 = +0.49$) — шум;
- Monthly: все 3 точки выше нуля (multihead хуже).

Сводная таблица результатов

freq	config	test sMAPE	std	Δ vs base	p-value
Hourly	baseline	9.493	0.13	—	—
Hourly	+RevIN	9.307	0.12	-0.19	0.008 **
Hourly	multihead	9.612	0.27	+0.12	0.639
Monthly	baseline	8.852	0.04	—	—
Monthly	+RevIN	8.894	0.05	+0.04	0.400
Monthly	multihead	8.905	0.02	+0.05	0.232

- единственный значимый эффект — RevIN на Hourly ($p = 0.008$);
- на Monthly — null effect, разница в пределах std;
- multihead не улучшает baseline ни на одной частоте.

EXP1 — RevIN

- **Hourly:** значимое улучшение -0.19 п.п. sMAPE, $p = 0.008$, эффект воспроизводится во всех 3 сетах;
- **Monthly:** null effect ($\Delta = 0.04$, $p > 0.4$);
- RevIN сходится раньше baseline'a (28k vs 35k шагов на Hourly) — важно фиксировать best-val.

EXP3 — Multi-head

- гипотеза дешёвого ансамбля **не подтвердилась**;
- усреднение хуже лучшей одиночной головы (sMAPE-голова);
- MSE-голова стабильно слабая, тянет среднее вниз;
- общий backbone не может одновременно служить трём геометриям ошибки.

Лимитации

- Monthly: best-val на step 49k и 48k $\Rightarrow$ не дообучено, выводы по Monthly предварительные.

Спасибо за внимание